

Phân tích đặc điểm khách hàng để dự đoán rời bỏ bằng các mô hình tổ hợp lai và kỹ thuật cân bằng lớp

Cao Minh Trí^{1,2}[23521635], Nguyễn Minh Trí^{1,2}[23521643], Từ Lê Việt
Hoàng^{1,2}[23521851]

¹ University of Information Technology, Ho Chi Minh City, Vietnam

² Vietnam National University, Ho Chi Minh City, Vietnam
{23521635,23521643,23521851}@gm.uit.edu.vn

Tóm tắt nội dung Trong bối cảnh kinh doanh hiện đại đầy biến động, việc thấu hiểu khách hàng để giảm thiểu tỷ lệ rời bỏ (churn) là vô cùng quan trọng. Nghiên cứu này đi sâu vào quá trình phân tích tính cách khách hàng thông qua một tập dữ liệu phong phú bao gồm các biến như độ tuổi, học vấn, thu nhập và thói quen chi tiêu. Trọng tâm của nghiên cứu là khám phá kỹ thuật sinh dữ liệu tổng hợp nhằm xác định các đặc trưng tính cách khách hàng, áp dụng các kỹ thuật cân bằng dữ liệu như CTGAN và SMOTE. Chúng tôi đề xuất mô hình lai HSLR kết hợp các phương pháp học tổ hợp (bagging, boosting, stacking) với các bộ phân loại như Random Forest, XGBoost, LightGBM và AdaBoost. Kết quả thực nghiệm cho thấy phương pháp đề xuất, đặc biệt khi sử dụng dữ liệu sinh bởi SMOTE, đạt hiệu quả vượt trội trong việc dự đoán hành vi khách hàng và đảm bảo lợi thế cạnh tranh bền vững.

Keywords: Phân tích tính cách khách hàng · Dự đoán rời bỏ · Học máy · CTGAN · SMOTE · Ensemble Learning · Hồi quy Logistic · Dữ liệu mất cân bằng · XGBoost · LightGBM.

1 Giới thiệu

Trong môi trường kinh doanh hiện đại đầy cạnh tranh, khả năng thấu hiểu và dự đoán hành vi khách hàng đóng vai trò then chốt trong việc xây dựng lợi thế cạnh tranh bền vững. Phân tích tính cách khách hàng cho phép doanh nghiệp khai thác hiệu quả các tập dữ liệu lớn và đa chiều, từ đó phân nhóm khách hàng và cá nhân hóa sản phẩm, dịch vụ nhằm gia tăng mức độ gắn kết và lòng trung thành.

Tuy nhiên, việc xác định chính xác đặc điểm tính cách khách hàng vẫn là một thách thức lớn, đặc biệt trong bối cảnh dữ liệu mất cân đối, hành vi khách hàng phức tạp và tỷ lệ rời bỏ cao. Những tiến bộ gần đây trong học máy và tự động hóa quy trình xử lý dữ liệu đã mở ra cơ hội tiếp cận bài toán này một cách hệ thống và hiệu quả hơn, thông qua việc kết hợp nhiều nguồn dữ liệu nhân khẩu học và hành vi tiêu dùng.

Nghiên cứu này tập trung vào việc khai thác dữ liệu khách hàng đa thuộc tính (tuổi, học vấn, thu nhập, cấu trúc gia đình và mô hình chi tiêu) nhằm phân tích tính cách khách hàng và dự đoán hành vi rời bỏ. Trọng tâm của công trình là việc ứng dụng các kỹ thuật sinh dữ liệu tổng hợp và cân bằng lớp, bao gồm CTGAN, SMOTE và Borderline-SMOTE, kết hợp với các mô hình học tổ hợp như bagging, boosting và stacking để nâng cao hiệu quả dự báo.

Bằng cách tích hợp các bộ phân loại mạnh (RF, XGBoost, LightGBM, AdaBoost) cùng hồi quy Logistic ở tầng meta, nghiên cứu đề xuất một khung phân tích toàn diện và vững chắc. Hiệu suất mô hình được đánh giá thông qua nhiều chiến lược kiểm định và tập chỉ số đa dạng, nhằm đảm bảo tính tin cậy và khả năng khái quát hóa. Qua đó, nghiên cứu góp phần thu hẹp khoảng cách giữa phân tích dữ liệu và ứng dụng chiến lược, đồng thời khẳng định vai trò trung tâm của phân tích tính cách khách hàng trong các chiến lược kinh doanh dựa trên dữ liệu.

2 Các nghiên cứu liên quan

Các nghiên cứu về phân tích tính cách khách hàng và dự đoán hành vi rời bỏ chủ yếu khai thác các kỹ thuật học máy và học sâu, với trọng tâm vào việc xây dựng mô hình phân loại dựa trên dữ liệu hành vi và tương tác khách hàng. Những phương pháp truyền thống như hồi quy Logistic, cây quyết định và SVM đã được áp dụng rộng rãi, song thường thiếu phân tích so sánh toàn diện và bị giới hạn phạm vi dữ liệu hẹp, làm giảm khả năng khái quát hóa.

Một số công trình khai thác dữ liệu phi cấu trúc, dữ liệu mạng xã hội hoặc nhật ký tương tác để suy luận tính cách và churn, kết hợp các kỹ thuật khai phá văn bản, học sâu hoặc mô hình chủ đề. Mặc dù mang lại những góc nhìn mới, các nghiên cứu này thường gặp hạn chế về kích thước tập dữ liệu, số lượng đặc trưng tính cách được xem xét và thiếu đánh giá so sánh giữa nhiều mô hình.


Các hướng tiếp cận dựa trên mạng nơ-ron (MLP, CNN, RNN, ANN) cho thấy tiềm năng trong việc mô hình hóa các mối quan hệ phi tuyến phức tạp, đặc biệt trong các lĩnh vực như viễn thông và ngân hàng. Tuy nhiên, nhiều nghiên cứu chưa giải quyết triệt để vấn đề dữ liệu mất cân đối hoặc chưa khai thác hiệu quả sức mạnh của các phương pháp học tổ hợp.

Gần đây, các mô hình ensemble và decision forest, bao gồm Random Forest, Logistic Model Tree và các chiến lược stacking, đã chứng minh hiệu quả vượt trội trong bài toán dự đoán churn, ngay cả trong bối cảnh dữ liệu không cân bằng. Dù vậy, phần lớn các công trình vẫn chưa kết hợp một cách hệ thống giữa kỹ thuật cân bằng dữ liệu tiên tiến và khung học tổ hợp lai.

Trên cơ sở đó, nghiên cứu này đề xuất một cách tiếp cận toàn diện hơn, kết hợp sinh dữ liệu tổng hợp, cân bằng lớp và mô hình học tổ hợp lai cho bài toán phân tích tính cách khách hàng và dự đoán churn. Cách tiếp cận này nhằm khắc phục những hạn chế về dữ liệu, phạm vi đặc trưng và đánh giá mô hình trong các nghiên cứu trước, đồng thời cung cấp một khung phân tích có tính tổng quát và ứng dụng cao.

3 Các phương pháp

Nghiên cứu xây dựng một khung phương pháp tích hợp, kết hợp các kỹ thuật cân bằng dữ liệu tiên tiến (CTGAN, SMOTE và Borderline-SMOTE) với các mô hình phân loại mạnh, bao gồm Random Forest, AdaBoost, LightGBM và XGBoost, đồng thời đề xuất mô hình Hybrid Stacking dựa trên hồi quy Logistic nhằm nâng cao hiệu quả phân tích và dự báo.




Hình 1. Kiến trúc khung phương pháp đề xuất cho bài toán phân tích tính cách người tiêu dùng

3.1 Kỹ thuật cân bằng dữ liệu: CTGAN, SMOTE và Borderline-SMOTE

CTGAN (Conditional Tabular GAN): CTGAN là phương pháp dựa trên Mạng Đối nghịch Tạo sinh (Generative Adversarial Network – GAN) được sử

dụng để sinh dữ liệu tổng hợp cho các tập dữ liệu dạng bảng bị mất cân bằng. Mô hình bao gồm hai thành phần chính: bộ tạo (Generator) và bộ phân biệt (Discriminator). Bộ tạo học cách sinh ra các mẫu dữ liệu tổng hợp từ không gian tiềm ẩn, trong khi bộ phân biệt có nhiệm vụ phân biệt giữa dữ liệu thật và dữ liệu sinh.



Hình 2. Kiến trúc GAN cho việc sinh dữ liệu tập dữ liệu.

Hàm mất mát của bộ tạo và bộ phân biệt lần lượt được xác định như sau:

$$L_G = \log(1 - D(G(Z))) \quad (1)$$

$$L_D = -\log(D(X)) - \log(1 - D(G(Z))) \quad (2)$$

Thông qua quá trình huấn luyện đối nghịch, CTGAN tạo ra các mẫu dữ liệu tổng hợp có phân phối gần với dữ liệu gốc, qua đó giúp cân bằng dữ liệu và cải thiện hiệu suất của các mô hình học máy.


Bảng 1. Setting for the CTGAN

CTGAN Parameters	Setting
Epochs	300
Batch Size	500
Gen_dim	256, 256
Embedding_dim	128
Noise_dim	32

SMOTE (Synthetic Minority Over-sampling Technique): SMOTE là kỹ thuật lấy mẫu quá mức được sử dụng phổ biến nhằm cân bằng các tập dữ liệu bị mất cân bằng lớp. Phương pháp này tạo ra các mẫu tổng hợp cho lớp thiểu số bằng cách nội suy giữa một mẫu lớp thiểu số và các láng giềng gần nhất của nó trong không gian đặc trưng dựa trên thuật toán k -nearest neighbors.

Quá trình tạo mẫu tổng hợp được thực hiện theo công thức:

$$NewSample = MI + RM \times (NN - MI) \quad (3)$$



Hình 3. Phương pháp SMOTE để sinh dữ liệu tổng hợp.

Trong đó MI là mẫu thuộc lớp thiểu số, NN là láng giềng gần nhất của MI , và RM là một số ngẫu nhiên trong khoảng $(0, 1)$. Việc bổ sung các mẫu tổng hợp giúp cải thiện khả năng học của mô hình và giảm thiên lệch về lớp đa số.

Bảng 2. Setting for the SMOTE

SMOTE Parameters	Setting
Neighbors (k)	5
Sampling Strategy	Minority
Random State	None
N-job	None

Borderline-SMOTE: Borderline-SMOTE là một biến thể của SMOTE, tập trung tạo dữ liệu tổng hợp cho các mẫu thuộc lớp thiểu số nằm gần ranh giới phân lớp (decision boundary), nơi có nguy cơ bị phân loại sai cao. Phương pháp này sử dụng thuật toán k -nearest neighbors để xác định các mẫu lớp thiểu số

thuộc vùng biên và chỉ thực hiện lấy mẫu tăng cường trên các mẫu này, giúp cải thiện khả năng học ranh giới phân lớp của mô hình.

Quá trình tạo mẫu tổng hợp trong Borderline-SMOTE được thực hiện thông qua nội suy giữa các mẫu lớp thiểu số ở vùng biên và các láng giềng gần nhất của chúng trong cùng lớp, theo công thức:

$$NewSample = MI + \lambda \times (NN - MI) \quad (4)$$

trong đó MI là mẫu lớp thiểu số nằm ở vùng biên, NN là láng giềng gần nhất thuộc lớp thiểu số, và $\lambda \in (0, 1)$ là một số ngẫu nhiên.


Nhờ tập trung vào các mẫu quan trọng gần ranh giới phân lớp, Borderline-SMOTE giúp giảm hiện tượng chồng lấn lớp và nâng cao hiệu quả của các mô hình học máy trong bối cảnh dữ liệu mất cân bằng.

3.2 Các mô hình phân loại

Trong phần này, các bộ phân loại như Random Forest, AdaBoost, Light Gradient Boosting Machine, XGBoost và bộ phân loại stacking được sử dụng. Bộ phân loại stacking vận hành bằng cách sử dụng bốn thuật toán đã nêu làm các mô hình phân loại cơ sở và Logistic Regression làm mô hình phân loại Meta classifier.

1. Random Forest

Random Forest là một phương pháp học tập kết hợp (ensemble learning), hoạt động bằng cách kết hợp nhiều cây quyết định (decision trees) khác nhau để cải thiện hiệu suất tổng thể của mô hình. Đây là thuật toán sử dụng kỹ thuật bagging (bootstrap aggregating), trong đó dữ liệu được phân chia thành các tập con nhỏ hơn và huấn luyện cây quyết định trên mỗi tập con đó. Tất cả các cây quyết định được đa số chấp thuận trong rừng sẽ đưa ra dự đoán cuối cùng đối với mẫu kiểm tra đã cho.



Hình 4. Phương pháp bagging được sử dụng trong hệ thống đề xuất.

Trong Random Forest, mỗi cây quyết định được huấn luyện bằng cách sử dụng một lựa chọn ngẫu nhiên các điểm dữ liệu và được thay thế bằng kỹ thuật bootstrap aggregating. Đặc biệt, tại mỗi lần phân chia (split) trong cây quyết định, một tập hợp con ngẫu nhiên các đặc trưng (features) sẽ được chọn để xem xét thay vì sử dụng tất cả các đặc trưng. Cơ chế này giúp cải thiện khả năng tổng quát hóa (generalizability) của mô hình và giảm thiểu hiện tượng quá khớp (overfitting). Kết quả dự đoán cuối cùng cho một mẫu thử nghiệm cụ thể được xác định dựa trên sự đồng thuận của đa số các cây quyết định trong rừng.

2. AdaBoost

AdaBoost (Adaptive Boosting) là một kỹ thuật học máy tổ hợp khác được sử dụng rộng rãi, có chức năng kết hợp một số bộ phân loại yếu (weak classifiers) để nâng cao hiệu suất tổng thể của mô hình. Phương pháp này hoạt động bằng cách liên tục sử dụng các tập con của dữ liệu để huấn luyện bộ phân loại cơ sở, đồng thời tập trung nhiều hơn vào những quan sát bị phân loại sai trong các vòng lặp trước đó.

Nguyên lý cốt lõi của AdaBoost là điều chỉnh trọng số của từng quan sát trong tập huấn luyện qua mỗi vòng lặp, giúp mô hình chú trọng vào các điểm dữ liệu khó. Phương trình sau đây mô tả cách cập nhật trọng số của một quan sát, ký hiệu là w_i :

$$w_i = 0.5 \times \ln \left(\frac{1 - \text{error}_i}{\text{error}_i} \right) \quad (5)$$

trong đó error_i là tỷ lệ phân loại sai của bộ phân loại cơ sở tại vòng lặp đó. Sau khi các trọng số được cập nhật, bộ phân loại cơ sở được huấn luyện lại dựa trên trọng số mới của bộ dữ liệu. Dự đoán cuối cùng được tạo ra bằng cách kết hợp dự đoán của tất cả các bộ phân loại cơ sở, trong đó độ chính xác của từng bộ phân loại quyết định trọng số đóng góp của nó. Công thức dự đoán cuối cùng được biểu diễn như sau:

$$f(x) = \text{sign} \left(\sum_{i=1}^T \alpha_i h_i(x) \right) \quad (6)$$

Trong đó $h_i(x)$ là dự đoán của bộ phân loại thứ i và α_i là trọng số của bộ phân loại đó.

AdaBoost là một phương pháp học tổ hợp mạnh mẽ, được ứng dụng rộng rãi trong nhiều lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên và tin sinh học. Phương pháp này có khả năng cải thiện hiệu suất của các bộ phân loại yếu bằng cách giảm sai lệch (bias) và phương sai (variance). Ngoài ra, AdaBoost còn có ưu điểm là hiệu quả về mặt tính toán và dễ triển khai. Tuy nhiên, do nhạy cảm với dữ liệu nhiễu và các điểm ngoại lai, việc tiền xử lý dữ liệu là một bước quan trọng trước khi áp dụng phương pháp này.

3. LightGBM

LightGBM (Light Gradient Boosting Machine) là một khung tăng cường gradient dựa trên cây, được thiết kế nhằm đạt hiệu quả cao và khả năng mở

rộng tốt khi làm việc với các tập dữ liệu lớn và có số chiều cao. Mô hình hoạt động bằng cách phân chia lặp lại không gian đặc trưng thành các không gian con nhỏ hơn để xây dựng các cây quyết định, trong đó các điểm chia được xác định dựa trên việc tối ưu hàm mất mát. Để tăng tốc quá trình huấn luyện, LightGBM áp dụng thuật toán Gradient-based One-Side Sampling (GOSS), cho phép lựa chọn các mẫu dữ liệu quan trọng trong quá trình tìm kiếm điểm chia, từ đó giảm chi phí tính toán so với các phương pháp truyền thống. Dự đoán cuối cùng của mô hình được hình thành bằng cách kết hợp kết quả từ tất cả các cây quyết định. Công thức sau đây tạo ra dự đoán cuối cùng:

$$f(x) = \sum_{i=1}^n f_i(x) \quad (7)$$

Trong đó $f_i(x)$ là dự đoán của cây quyết định thứ i và n là tổng số cây quyết định. Các tác vụ học máy quy mô lớn thường xuyên sử dụng LightGBM vì thời gian huấn luyện ngắn và độ chính xác dự đoán tốt. LightGBM cung cấp một số giải pháp cho tính toán song song và phân tán có thể giảm thêm thời gian huấn luyện trong khi cũng xử lý dữ liệu nhiều chiều và các đặc trưng phân loại một cách dễ dàng.

4. XGBoost

Một hệ thống tăng cường gradient mã nguồn mở tập trung vào hiệu quả và khả năng mở rộng được gọi là XGBoost (eXtreme Gradient Boosting). Giống như các phương pháp tăng cường gradient khác, XGBoost huấn luyện một tập hợp (ensemble) các cây quyết định bằng cách phân chia lặp đi lặp lại không gian đặc trưng và huấn luyện một cây quyết định trên không gian con đã phân chia. Ý tưởng cơ bản đằng sau XGBoost là tối ưu hóa hàm mục tiêu bằng cách thêm các cây mới vào tập hợp. Hàm mục tiêu là thước đo hiệu suất của mô hình, và nó có thể khác nhau đối với các bài toán phân loại và hồi quy. Đối với các bài toán phân loại, hàm mục tiêu thường là hàm log-loss, được định nghĩa là:

$$L(y, f(x)) = -\frac{1}{n} \sum_{i=1}^n [y_i \times \log(f(x_i)) + (1 - y_i) \times \log(1 - f(x_i))] \quad (8)$$

Trong đó, n là số lượng quan sát, y_i biểu thị nhãn chính xác, và $f_i(x)$ biểu thị xác suất được dự đoán. Thông thường, sai số bình phương trung bình (mean squared error) đóng vai trò là hàm mất mát trong các vấn đề hồi quy.

$$L(y, f(x)) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 \quad (9)$$

XGBoost sử dụng thuật toán tối ưu hóa dựa trên gradient trái ngược với các kỹ thuật truyền thống hơn như tìm kiếm toàn diện hoặc các thuật toán xấp xỉ để nhanh chóng khám phá điểm chia lý tưởng. Ngoài ra, nó sử dụng một phương pháp được gọi là regularization (chính quy hóa) để giảm bớt sự

quá khớp (overfitting) và tăng cường khả năng tổng quát hóa của mô hình. Hàm mục tiêu bao gồm thuật ngữ regularization, được định nghĩa như sau:

$$L(y, f(x)) + \gamma T + \gamma \sum w_i^2 \quad (10)$$

Trong đó w_i là trọng số của đặc trưng thứ i , γ là tham số độ phức tạp, và $\sum w_i^2$ là thuật ngữ điều chuẩn hóa L2. Thuật ngữ điều chuẩn hóa này giúp giảm hiện tượng quá khớp (overfitting) và được xem là một thành phần quan trọng trong việc cải thiện khả năng tổng quát hóa của mô hình. XGBoost được coi là một trong những thuật toán học máy mạnh mẽ và được sử dụng rộng rãi nhất, nổi bật nhờ thời gian huấn luyện nhanh và độ chính xác dự đoán cao. Thuật toán này có khả năng xử lý hiệu quả các đặc trưng dạng phân loại và dữ liệu có số chiều lớn, đồng thời cung cấp nhiều tùy chọn xử lý song song và phân tán, qua đó giúp giảm đáng kể thời gian huấn luyện.

5. Logistic Regression

Đối với các bài toán phân loại, các thuật toán học có giám sát như hồi quy Logistic thường được sử dụng. Mục tiêu cốt lõi của hồi quy Logistic là mô hình hóa xác suất xảy ra của một kết quả nhị phân (chẳng hạn như thành công hoặc thất bại, tương ứng với 1 hoặc 0) dựa trên một tập dữ liệu đầu vào cho trước. Đầu ra của mô hình là một giá trị xác suất trong khoảng từ 0 đến 1, có thể được diễn giải như xác suất thuộc về lớp dương. Hồi quy Logistic sử dụng hàm logistic, còn được gọi là hàm sigmoid, để mô hình hóa xác suất của lớp dương theo biểu thức toán học sau:

$$p(y = 1 | x) = \frac{1}{1 + e^{-(w^T x + b)}}, \quad (11)$$

Trong đó w là vector trọng số, b là hệ số chệch, và x là vector đặc trưng đầu vào. Các tham số của mô hình, bao gồm vector trọng số và hệ số chệch, được ước lượng từ tập dữ liệu huấn luyện.

Mục tiêu của thuật toán học là tìm ra các giá trị của w và b sao cho khả năng xảy ra (likelihood) của dữ liệu huấn luyện đạt giá trị lớn nhất. Việc xác định các tham số tối ưu này thường được thực hiện thông qua phương pháp ước lượng hợp lý cực đại (Maximum Likelihood Estimation – MLE). Với một mô hình cho trước, hàm likelihood được định nghĩa là xác suất quan sát được tập dữ liệu huấn luyện. Hàm log-likelihood tương ứng được biểu diễn như sau:


$$\mathcal{L}(w, b) = \sum_i [y_i \log p(y = 1 | x_i) + (1 - y_i) \log(1 - p(y = 1 | x_i))]. \quad (12)$$

Trong nghiên cứu này, hồi quy Logistic được sử dụng như một bộ phân loại meta trong kiến trúc học tổ hợp stacking.

3.3 Hybrid Stacking Based Logistic Regression (HSLR)

Bốn bộ học cơ sở (ADA Boost, XGBoost, Random Forests, và LightGBM) đã được sử dụng trong bộ phân loại tập hợp stacking (stacking ensemble classifier)

cùng với một bộ học meta (meta-learner) là hồi quy logistic; chúng được huấn luyện trên dữ liệu đầu vào và các dự đoán của chúng được sử dụng làm đặc trưng (features) cho bộ học meta. Sau đó, một dự đoán cuối cùng được đưa ra bởi bộ học meta bằng cách kết hợp các dự đoán của các bộ học cơ sở. Bởi vì nó có thể kết hợp các lợi ích của nhiều mô hình trong khi giảm thiểu những nhược điểm của chúng, phương pháp tập hợp stacking là hiệu quả. Trong phương pháp tập hợp stacking, bộ phân loại meta LR (Logistic Regression) được huấn luyện để pha trộn các dự đoán từ các bộ phân loại cơ sở như là các đặc trưng đầu vào để tạo ra một dự đoán cuối cùng.



Hình 5. HSLR (RF, LGBM, XGB, ADA), (LR).

Thuật toán: Bộ phân loại tập hợp stacking với meta-learner hồi quy Logistic

Đầu vào:

- Tập dữ liệu huấn luyện: $D_{\text{train}} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$
- Tập dữ liệu kiểm thử: $D_{\text{test}} = \{x'_1, x'_2, \dots, x'_m\}$
- Các bộ học cơ sở: $BL = \{\text{RF}, \text{XGB}, \text{LGBM}, \text{ADA}\}$ (RF: Random Forest, XGB: XGBoost, LGBM: LightGBM, ADA: ADA Boost)
- Bộ học Meta: Hồi quy Logistic (LR)

Quy trình:

-
- 1: **for** mỗi bộ học cơ sở $bl \in BL$ **do**
 - 2: Huấn luyện bl trên D_{train} để có được mô hình đã huấn luyện M_{bl}
 - 3: Sử dụng M_{bl} để dự đoán các nhãn của D_{train} , lưu trữ các dự đoán là $P_{bl_{\text{train}}}$
 - 4: Sử dụng M_{bl} để dự đoán các nhãn của D_{test} , lưu trữ các dự đoán là $P_{bl_{\text{test}}}$
 - 5: **end for**
 - 6: Kết hợp các dự đoán $P_{bl_{\text{train}}}$ từ tất cả các bộ học cơ sở để tạo thành một ma trận đặc trưng mới F_{train} cho D_{train}
 - 7: Kết hợp các dự đoán $P_{bl_{\text{test}}}$ từ tất cả các bộ học cơ sở để tạo thành một ma trận đặc trưng mới F_{test} cho D_{test}
 - 8: Huấn luyện bộ học meta LR trên F_{train} sử dụng các nhãn thực từ D_{train} để có được mô hình meta đã huấn luyện M_{LR}
 - 9: Sử dụng M_{LR} để dự đoán các nhãn của F_{test} , lưu trữ các dự đoán là P
 - 10: **Trả về** P
-

Đầu ra:

- Các dự đoán trên tập dữ liệu kiểm thử: $P = \{y'_1, y'_2, \dots, y'_m\}$

Để kết hợp các dự đoán của các bộ học cơ sở, một meta-learner được huấn luyện trên các dự đoán được thực hiện bởi các bộ học cơ sở cho mỗi trường hợp đầu vào. Trong trường hợp này, một meta-learner hồi quy logistic (LR) được sử dụng. Meta-learner lấy các dự đoán được thực hiện bởi các bộ học cơ sở làm các đặc trưng đầu vào và học cách kết hợp chúng để đưa ra một dự đoán cuối cùng. Bộ phân loại meta LR được huấn luyện để pha trộn các dự đoán từ các bộ phân loại cơ sở như là các đặc trưng đầu vào để tạo ra một dự đoán cuối cùng.

Khi chúng tôi khép lại phần phương pháp luận của mình, chúng tôi nhấn mạnh cách tiếp cận đổi mới được thực hiện trong nghiên cứu này. Bằng cách tích hợp hài hòa một loạt các bộ phân loại mạnh mẽ và các kỹ thuật cân bằng lớp, giải pháp của chúng tôi đứng vững như một công cụ mạnh mẽ trong bối cảnh phân loại tính cách khách hàng, hứa hẹn độ chính xác chưa từng có trong phân tích dự đoán.

4 Thực nghiệm

4.1 Bộ dữ liệu

Bộ dữ liệu thu thập đại diện cho Phân tích Tính cách Người tiêu dùng, một kỹ thuật được sử dụng để xác định khách hàng lý tưởng của một công ty. Nó bao gồm 2240 mẫu, với 1906 mẫu thuộc lớp tiêu cực và 334 mẫu thuộc lớp tích cực.

Bảng 3. Mô tả bộ dữ liệu

Lớp	Số mẫu
Lớp tích cực	334
Lớp tiêu cực	1906
Tổng	2240

Bộ dữ liệu bao gồm thông tin khách hàng như năm sinh, giáo dục, tình trạng hôn nhân, liệu họ có con cái không, thu nhập, và một số thuộc tính khác. Bộ dữ liệu được cân bằng sử dụng các cách tiếp cận SMOTE, CTGAN và Borderline-SMOTE, dẫn đến số lượng mẫu bằng nhau cho cả hai lớp.

Bảng 4. Phân bố bộ dữ liệu sau khi cân bằng lớp

Lớp	Số mẫu ban đầu	Số mẫu sau cân bằng
Lớp tích cực	334	1906
Lớp tiêu cực	1906	1906
Tổng	2240	3812

4.2 Các tiêu chí đánh giá

Để đánh giá toàn diện hiệu suất của các mô hình dự báo, nghiên cứu sử dụng nhiều tiêu chí đánh giá khác nhau nhằm phản ánh chính xác khả năng phân loại trong bối cảnh dữ liệu mất cân bằng. Các chỉ số đánh giá được tính toán dựa trên bốn giá trị cơ bản của ma trận nhầm lẫn gồm: số lượng mẫu dương tính được phân loại đúng (True Positive – TP), số lượng mẫu âm tính được phân loại đúng (True Negative – TN), số lượng mẫu dương tính bị phân loại sai (False Negative – FN) và số lượng mẫu âm tính bị phân loại sai (False Positive – FP).

Accuracy (Độ chính xác) đo lường tỷ lệ các mẫu được phân loại đúng trên tổng số mẫu trong tập dữ liệu, được xác định theo công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Tuy nhiên, chỉ số này có thể gây sai lệch trong trường hợp dữ liệu bị mất cân bằng giữa các lớp.

Precision (Độ chính xác dương) phản ánh tỷ lệ các mẫu được dự đoán là dương tính và thực sự là dương tính, được tính như sau:

$$Precision = \frac{TP}{TP + FP}$$

Recall (Độ thu hồi), hay còn gọi là độ nhạy, đo lường khả năng của mô hình trong việc phát hiện đúng các mẫu dương tính trong tổng số các mẫu dương tính thực tế:

$$Recall = \frac{TP}{TP + FN}$$

F1-score là trung bình điều hòa giữa Precision và Recall, giúp cân bằng giữa hai chỉ số này trong các bài toán phân loại không cân bằng:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

MCC (Matthews Correlation Coefficient) đo lường mức độ tương quan giữa nhãn dự đoán và nhãn thực tế, với giá trị nằm trong khoảng từ -1 đến $+1$.

Chỉ số MCC được đánh giá là thước đo tin cậy trong các bài toán phân loại nhị phân mất cân bằng:

$$MCC = \frac{(TP \times TN) - (FP \times FN)}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

ROC-AUC (Receiver Operating Characteristic – Area Under the Curve) biểu diễn khả năng phân biệt giữa hai lớp của mô hình thông qua mối quan hệ giữa tỷ lệ dương tính đúng (TPR) và tỷ lệ dương tính giả (FPR) tại các ngưỡng phân loại khác nhau. Giá trị AUC càng lớn thì khả năng phân biệt của mô hình càng tốt.

4.3 Kết quả và bàn luận

Independence Set Testing: Trong kịch bản kiểm tra tập độc lập, kết quả cho thấy dữ liệu sinh bởi SMOTE và Borderline-SMOTE vượt trội hơn CTGAN trên hầu hết các chỉ số. Với CTGAN, HSLR đạt hiệu suất cao nhất (Accuracy: 92.294%, MCC: 92.254%). Tuy nhiên, khi sử dụng SMOTE và Borderline-SMOTE, hiệu suất tăng đáng kể, trong đó HSLR dẫn đầu với Accuracy cao nhất 94.483% và MCC cao nhất 94.517% trên Borderline-SMOTE.

Kết quả khẳng định HSLR kết hợp với các kỹ thuật *oversampling* thông minh (đặc biệt là Borderline-SMOTE) mang lại khả năng dự đoán và phân biệt lớp tốt nhất trong dữ liệu mất cân bằng.

Bảng 5. Kết quả đánh giá với dữ liệu sinh bởi CTGAN sử dụng Independent Set Testing

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	91.419	96.198	86.644	83.297	91.171	0.975
XGB	91.769	94.872	88.699	83.739	91.681	0.976
ADA	88.354	95.556	80.993	77.722	87.674	0.958
LGBM	91.769	95.370	88.185	83.807	91.637	0.974
HSLR	92.294	94.928	89.726	84.733	92.254	0.976

Bảng 6. Kết quả đánh giá với dữ liệu sinh bởi SMOTE sử dụng Independent Set Testing

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	94.658	93.664	95.797	89.340	94.719	0.982
XGB	93.783	93.403	94.221	87.569	93.810	0.984
ADA	87.128	86.301	88.266	74.275	87.273	0.950
LGBM	94.133	93.599	94.746	88.273	94.169	0.983
HSLR	94.046	93.739	94.396	88.093	94.066	0.983

Bảng 7. Kết quả đánh giá với dữ liệu sinh bởi Borderline-SMOTE sử dụng Independent Set Testing

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	94.834	93.537	96.322	89.707	94.909	0.984
XGB	94.046	92.699	95.622	88.135	94.138	0.986
ADA	87.741	85.738	90.543	75.600	88.075	0.951
LGBM	93.958	92.979	95.096	87.939	94.026	0.985
HSLR	94.483	93.945	95.096	88.973	94.517	0.985

5-Fold Cross Validation: Trong kịch bản đánh giá 5-fold cross validation, kết quả cho thấy xu hướng tương tự như kiểm tra tập độc lập: dữ liệu sinh bởi SMOTE và Borderline-SMOTE tiếp tục vượt trội hơn CTGAN trên hầu hết các chỉ số. Với CTGAN, HSLR đạt hiệu suất cao nhất (Accuracy: 91.967%, MCC: 91.810%). Tuy nhiên, khi sử dụng SMOTE và Borderline-SMOTE, hiệu suất được cải thiện rõ rệt, trong đó HSLR duy trì vị trí dẫn đầu với Accuracy cao nhất 94.299%, F1 cao nhất 94.931% và MCC cao nhất 89.875% trên Borderline-SMOTE.

Kết quả này cho thấy HSLR khi kết hợp với các kỹ thuật *oversampling* thông minh, đặc biệt là Borderline-SMOTE, không chỉ cải thiện hiệu suất dự đoán mà còn duy trì được tính ổn định cao qua các lần phân chia dữ liệu. Điều này chứng tỏ mô hình có khả năng học hiệu quả trên dữ liệu mất cân bằng mà không bị phụ thuộc quá mức vào cách chia tập huấn luyện.

Bảng 8. Kết quả đánh giá với dữ liệu sinh bởi CTGAN sử dụng 5-Fold Cross Validation

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	91.629	95.554	87.501	83.583	91.343	0.974
XGB	91.630	94.618	88.469	83.469	91.426	0.974
ADA	89.302	94.617	83.557	79.186	88.736	0.958
LGBM	91.742	94.846	88.469	83.712	91.530	0.975
HSLR	91.967	94.583	89.213	84.095	91.810	0.975

Bảng 9. Kết quả đánh giá với dữ liệu sinh bởi SMOTE sử dụng 5-Fold Cross Validation

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	94.069	93.187	95.119	94.134	88.176	0.984
XGB	93.056	92.016	94.294	93.138	86.143	0.982
ADA	87.539	87.107	88.213	87.644	75.106	0.949
LGBM	92.905	92.307	93.618	92.955	85.824	0.983
HSLR	94.032	93.611	94.519	94.060	88.074	0.984

Bảng 10. Kết quả đánh giá với dữ liệu sinh bởi Borderline-SMOTE sử dụng 5-Fold Cross Validation

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	94.877	94.459	95.375	94.906	89.774	0.986
XGB	93.642	93.179	94.219	93.682	87.315	0.985
ADA	87.598	86.721	88.806	87.740	75.239	0.952
LGBM	93.957	94.131	93.799	93.951	87.939	0.985
HSLR	94.929	94.977	94.902	94.931	89.875	0.986

10-Fold Cross Validation: Trong kịch bản đánh giá 10-fold cross validation, kết quả tiếp tục củng cố xu hướng đã quan sát ở các phương pháp trước: dữ liệu sinh bởi SMOTE và Borderline-SMOTE vượt trội rõ rệt so với CTGAN trên hầu hết các chỉ số. Với CTGAN, HSLR đạt hiệu suất cao nhất (Accuracy: 92.005%, MCC: 91.832%). Tuy nhiên, khi sử dụng SMOTE và Borderline-SMOTE, hiệu suất tăng đáng kể, trong đó HSLR tiếp tục dẫn đầu với Accuracy cao nhất 95.192%, F1 cao nhất 95.199% và MCC cao nhất 90.408% trên Borderline-SMOTE.

Kết quả từ kiểm định chéo 10-fold tiếp tục khẳng định ưu thế vượt trội của HSLR kết hợp với Borderline-SMOTE trong việc nâng cao khả năng tổng quát hóa của mô hình. Việc sử dụng số lượng fold lớn hơn giúp đánh giá mô hình một cách chặt chẽ hơn, đồng thời giảm phương sai trong ước lượng hiệu suất, qua đó phản ánh chính xác hơn năng lực dự đoán thực tế trên dữ liệu mất cân bằng.

Bảng 11. Kết quả đánh giá với dữ liệu sinh bởi CTGAN sử dụng 10-Fold Cross Validation


Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	91.817	95.725	87.722	83.984	91.521	0.976
XGB	91.854	95.011	88.541	83.978	91.620	0.974
ADA	89.564	94.771	84.003	79.735	89.014	0.959
LGBM	92.080	94.832	89.212	84.390	91.890	0.975
HSLR	92.005	94.684	89.211	84.213	91.832	0.976

Bảng 12. Kết quả đánh giá với dữ liệu sinh bởi SMOTE sử dụng 10-Fold Cross Validation

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	94.106	93.315	95.045	94.160	88.251	0.985
XGB	93.543	92.500	94.822	93.628	87.150	0.983
ADA	87.610	87.384	87.990	87.674	75.242	0.952
LGBM	93.694	93.329	94.146	93.720	87.420	0.984
HSLR	94.181	93.787	94.671	94.211	88.396	0.985

Bảng 13. Kết quả đánh giá với dữ liệu sinh bởi Borderline-SMOTE sử dụng 10-Fold Cross Validation

Mô hình	Acc	Pre	Rec	F1	MCC	AUC
RF	95.086	94.477	95.797	95.120	90.205	0.986
XGB	93.799	93.456	94.219	93.821	87.630	0.985
ADA	87.440	86.745	88.439	87.564	74.931	0.950
LGBM	93.931	93.821	94.115	93.941	87.914	0.985
HSLR	95.192	94.994	95.430	95.199	90.408	0.987

**Hình 6.** So sánh Accuracy giữa các mô hình với các kỹ thuật cân bằng dữ liệu khác nhau trong kiểm định chéo 10-fold.

Phân tích trọng số mô hình HSLR: Dựa trên kết quả thực nghiệm vượt trội của kỹ thuật Borderline-SMOTE, chúng tôi tiến hành phân tích sâu hơn cấu trúc của mô hình HSLR đã được huấn luyện trên tập dữ liệu này. Các tham số của bộ học meta (Logistic Regression) phản ánh mức độ đóng góp của từng thuật toán cơ sở vào quyết định dự báo cuối cùng. Phương trình hồi quy tuyến tính z được xác định như sau:

$$z = -5.0911 + 6.3366 \cdot P_{RF} + 1.5568 \cdot P_{XGB} + 1.0198 \cdot P_{LGBM} + 0.8219 \cdot P_{ADA} \quad (13)$$

Trong đó, P_{RF} , P_{XGB} , P_{LGBM} , P_{ADA} lần lượt là xác suất dự báo của Random Forest, XGBoost, LightGBM và AdaBoost. Kết quả cho thấy **Random Forest** có trọng số lớn nhất (≈ 6.34), đóng vai trò quan trọng nhất trong việc định hình kết quả dự đoán, tiếp theo là XGBoost. Hệ số chặn âm lớn (-5.09) giúp mô hình giảm thiểu tỷ lệ dương tính giả (False Positive) bằng cách yêu cầu bằng chứng mạnh mẽ hơn từ các mô hình con trước khi phân loại khách hàng rời bỏ.

5 Tổng kết

Nghiên cứu này đã giải quyết thách thức về sự mất cân bằng lớp trong các mô hình học máy bằng cách sử dụng CTGAN, SMOTE và Borderline-SMOTE để tạo ra dữ liệu tổng hợp. Các kết quả chỉ ra sự vượt trội của SMOTE và Borderline-SMOTE so với CTGAN về các chỉ số hiệu suất khác nhau. Tập dữ liệu được sử dụng đã thể hiện sự mất cân bằng lớp, điều này có thể khiến các mô hình học máy bị thiên vị về phía lớp đa số. Vấn đề này đã được giải quyết bằng cách tạo ra dữ liệu tổng hợp sử dụng CTGAN, SMOTE và Borderline-SMOTE.

Mô hình HSLR đề xuất đã sử dụng nhiều bộ phân loại khác nhau, và hiệu suất của nó được đánh giá bằng các chỉ số như điểm độ chính xác (accuracy), độ chính xác (precision), độ thu hồi (recall), điểm F1, MCC và điểm ROC. Cách tiếp cận Borderline-SMOTE đã mang lại kết quả cao nhất, vượt trội hơn so với các phương pháp hiện có.

Các kế hoạch trong tương lai bao gồm việc thu thập thêm dữ liệu và khám phá các kiến trúc nơ-ron sâu như FCN, CNN, LSTM và GRU. Các phát hiện của nghiên cứu này cung cấp những hiểu biết sâu sắc về việc ứng dụng học máy và học sâu trong việc giải quyết các vấn đề mất cân bằng lớp, với các ứng dụng tiềm năng trong các lĩnh vực như y tế, tài chính và an ninh.

Bảng 14. Danh sách các từ ngữ viết tắt

Ký hiệu	Mô tả
RF	Random Forest
XGB	eXtreme Gradient Boosting
ADA	AdaBoost
LGBM	Light Gradient Boosting Machine
LR	Logistic Regression
SMOTE	Synthetic Minority Over-sampling Technique
Borderline-SMOTE	Borderline Synthetic Minority Over-sampling Technique
GAN	Generative Adversarial Network
CTGAN	Conditional Tabular Generative Adversarial Network
CNN	Convolutional Neural Network
GRU	Gated Recurrent Unit

Tài liệu

1. S. Kumar, “A survey on customer churn prediction using machine learning techniques,” *International Journal of Computer Applications*, vol. 154, no. 10, pp. 13–16, 2016.
2. N. N. Y. Vo, S. Liu, X. Li, and G. Xu, “Leveraging unstructured call log data for customer churn prediction,” *Knowledge-Based Systems*, vol. 212, Art. no. 106586, 2021.
3. H. Zhao, Z. Liu, X. Yao, and Q. Yang, “Machine learning-based sentiment analysis of online product reviews,” *Information Processing & Management*, vol. 58, no. 5, Art. no. 102656, 2021.

4. N. Chaudhuri, G. Gupta, V. Vamsi, and I. Bose, "Predicting customers' purchase behavior using deep learning," *Decision Support Systems*, vol. 149, Art. no. 113622, 2021.
5. J. Sun *et al.*, "Digital twins in human understanding: Recognizing personality traits," *International Journal of Computer Integrated Manufacturing*, vol. 34, no. 7–8, pp. 860–873, 2021.
6. N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
7. H. Han, W.-Y. Wang, and B.-H. Mao, "Borderline-SMOTE: A new over-sampling method in imbalanced data sets learning," in *Proc. Int. Conf. Intell. Comput. (ICIC)*, LNCS, vol. 3644, pp. 878–887, 2005.
8. L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni, "Modeling tabular data using conditional GAN," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
9. L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
10. Y. Freund and R. E. Schapire, "A decision-theoretic generalization of on-line learning and an application to boosting," *Journal of Computer and System Sciences*, vol. 55, no. 1, pp. 119–139, 1997.
11. T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, pp. 785–794, 2016.
12. G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NIPS)*, pp. 3146–3154, 2017.
13. F. E. Usman-Hamza *et al.*, "Intelligent decision forest models for customer churn prediction," *Applied Sciences*, vol. 12, no. 16, p. 8270, 2022.
14. S. Arockia Panimalar and A. Krishnakumar, "Customer churn prediction model in cloud environment," *Engineering Applications of Artificial Intelligence*, vol. 126, Art. no. 107015, 2023.
15. A. P. Bradley, "The use of the area under the ROC curve in the evaluation of machine learning algorithms," *Pattern Recognition*, vol. 30, no. 7, pp. 1145–1159, 1997.
16. J. Japkowicz and S. Stephen, "The class imbalance problem: A systematic study," *Intelligent Data Analysis*, vol. 6, no. 5, pp. 429–449, 2002.
17. H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
18. K. Chaudhary *et al.*, "Machine learning-based modeling for social media consumer behavior," *Journal of Big Data*, vol. 8, no. 1, pp. 1–20, 2021.
19. Kaggle, "Customer Personality Analysis Dataset." [Online]. Available: <https://www.kaggle.com/datasets/imakash3011/customer-personality-analysis>. [Accessed: Dec. 30, 2025].
20. N. Ahmad, M. J. Awan, H. Nobanee, A. M. Zain, A. Naseem, and A. Mahmoud, "Customer personality analysis for churn prediction using hybrid ensemble models and class balancing techniques," *IEEE Access*, vol. 12, pp. 1865–1879, 2024.